

TALLER PRÁCTICO MOMENTO 2: ANÁLISIS DE DATOS CON PANDAS

Objetivo: Aprender a leer, limpiar, transformar y analizar datos usando Pandas, y luego visualizarlos con Matplotlib y Seaborn, trabajando con datos reales que contienen errores.

ESTRUCTURA DEL TALLER

Archivos por usar: ventas.csv, cliente.csv

PARTE 1: LECTURA Y EXPLORACIÓN DE DATOS

Paso 1: Importar librerías

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

Paso 2: Leer archivos con .read_csv()

Carga archivos CSV como DataFrame.

```
ventas = pd.read_csv("ventas.csv")
clientes = pd.read_csv("cliente.csv")
```

Paso 3: Usar usecols

Leer solo columnas específicas.

```
ventas_reducido = pd.read_csv("ventas.csv", usecols=["producto", "total"])
```

Paso 4: Explorar estructura

.shape: Muestra filas y columnas

```
ventas.shape
```

.info(): Tipos de datos y valores nulos

```
clientes.info()
```

.describe(): Estadísticas básicas

```
ventas.describe()
```

Paso 5: Acceso a columnas (notación punto)

```
ventas.total  
clientes.edad
```

Paso 6: Indexación

```
ventas.index = ventas.id_venta
```

ENTREGABLE 1: Script .py y Pantallazos de .shape, .info(), .describe()

PARTE 2: LIMPIEZA DE DATOS

Problemas detectados en los CSV: Valores nulos, tipos incorrectos, fechas mal formateadas, texto inconsistente.

Paso 1: Valores nulos

.dropna()

```
clientes_sin_nulos = clientes.dropna()
```

.fillna()

```
clientes["edad"] = clientes["edad"].fillna(0)
```

Paso 2: Duplicados

```
clientes = clientes.drop_duplicates()
```

Paso 3: Corrección de tipos

```
clientes["edad"] = pd.to_numeric(clientes["edad"], errors="coerce")
clientes["salario"] = pd.to_numeric(clientes["salario"], errors="coerce")
```

Paso 4: Limpieza de texto

```
clientes["ciudad"] = clientes["ciudad"].str.strip().str.title()
clientes["activo"] = clientes["activo"].str.upper()
```

Paso 5: Fechas

```
clientes["fecha_registro"] = pd.to_datetime(clientes["fecha_registro"],
ventas["fecha_venta"] = pd.to_datetime(ventas["fecha_venta"])
```

ENTREGABLE 2: Código de limpieza y Evidencia antes/después (pantallazos)

PARTE 3: TRANSFORMACIÓN Y ANÁLISIS

Paso 1: .loc y .iloc

.loc (por etiquetas) y .iloc (por posición)

```
ventas.loc[0:5, ["producto", "total"]]
ventas.iloc[0:5, 0:3]
```

Paso 2: groupby()

```
ventas.groupby("categoria")["total"].sum()
```

Paso 3: Split y Combine

```
grupo = ventas.groupby("canal")
ventas_online = grupo.get_group("Online")
```

Paso 4: merge()

```
df = pd.merge(ventas, clientes, on="id_cliente")
```

Paso 5: concat()

```
df_total = pd.concat([ventas, ventas])
```

ENTREGABLE 3: Código de análisis y Resultados de agrupaciones

PARTE 4: VISUALIZACIÓN

Gráfico 1: Ventas por categoría

```
ventas.groupby("categoria")["total"].sum().plot(kind="bar")
plt.title("Ventas por categoría")
plt.show()
```

Gráfico 2: Método de pago

```
sns.countplot(data=ventas, x="metodo_pago")
plt.show()
```

Gráfico 3: Relación salario vs puntaje

```
sns.scatterplot(data=clientes, x="salario", y="puntaje")
plt.show()
```

ENTREGABLE 4: Imágenes de gráficos (.png) y Código usado

PARTE 5: DESAFÍO FINAL

Responder preguntas de negocio:

1. ¿Qué categoría genera más ingresos?
2. ¿Qué canal vende más?
3. ¿Clientes con mayor salario compran más?
4. ¿Qué método de pago es más usado?
5. ¿Top 5 clientes con más compras?

RETO: Debes limpiar ambos datasets, unirlos con merge(), crear mínimo 3 gráficos y usar groupby, loc/iloc, fillna/dropna y concat/merge.

ENTREGABLE FINAL: Código .py, Evidencias (pantallazos) y Visualizaciones

BONUS (Nivel Pro)

```
ventas["mes"] = ventas["fecha_venta"].dt.month
ventas.groupby("mes")["total"].sum()
```

Todo debe ser entregado en enlace de repositorio por medio del formulario de entrega y de manera individual.